Projet de Séries Temporelles

Modélisation ARIMA d'une série temporelle

Imane Bayoub, Elise Fontaine

2024 - 2025

Sommaire

Partie 1. Les données **2**
La série temporelle étudiée 2
Stationnarisation de la série 2
Partie 2: Modélisation SARIMA **4**
Identification des ordres maximums pertinents 4
Modèle ARIMA retenu et justification 5
Partie 3: Prévision **6**
Équation vérifiée par la région de confiance à 95 % 6
Question ouverte 8
Annexes **9**
Annexe 1: Représentation graphique de la série (Gt) et son ACF 9
Annexe 2: Représentation graphique de la série (Zt) et son ACF 9
Annexe 3: Représentation graphique de la série finale (Yt) et son ACF 9
Annexe 4: Représentation graphique des PACF 10
Annexe 5: Représentation graphique des caractéristiques des résidus 11
Annexe 6: Tableau des différents modèles testés 11
Annexe 7: Code R 12

Partie 1. Les données

La série temporelle étudiée

Notre étude porte sur l'indice brut de la production industrielle (base 100 en 2021) pour la fabrication d'armes et de munitions en France, correspondant à la classe 25.40 de la nomenclature d'activités française (NAF rév. 2). Les données sont disponibles sur le site de l'INSEE. La série est de fréquence mensuelle et couvre la période allant de janvier 1990 à mars 2025. Cet indice est calculé par l'INSEE à partir des enquêtes de branche menées auprès des entreprises industrielles, en s'appuyant sur les sources du Service de la Statistique et de la Prospective (SSP), du Service de l'observation et des statistiques (SOeS), ainsi que d'organismes professionnels spécialisés. Nous noterons cette série $(X_t)_{t \in T}$ avec $T = \{1, \dots, \bar{t}\}$, l'ensemble des dates d'observation.

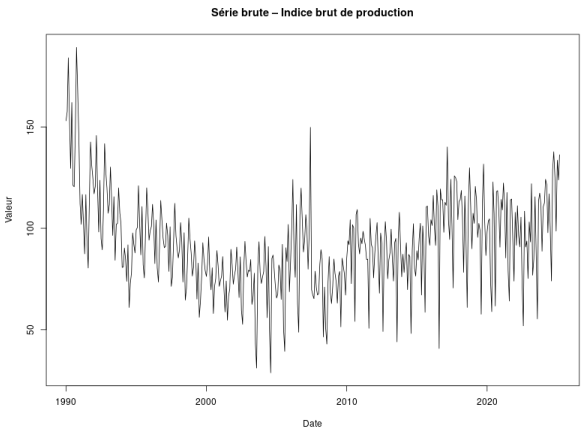

Figure 1 – Représentation graphique de la série brute étudiée

Stationnarisation de la série

La série brute présente une tendance marquée sur le long terme ainsi qu'une certaine volatilité au cours du temps, justifiant une transformation préalable visant à stabiliser la variance. Pour cela, nous avons appliqué en premier lieu une transformation de Box-Cox avec paramètre λ=0.51. On note la série transformée : $G_t = \frac{(X_t^{\lambda} - 1)}{\lambda}$ $si\, \lambda \neq 0$; $G_t = log(X_t)$ sinon

Bien que l'impact visuel de cette transformation soit modéré, elle permet de réduire l'hétéroscédasticité résiduelle présente au début de la série, sans altérer la structure globale des données.
L'étude des auto-corrélations de la série (Figure 10 en Annexe 1) ainsi que l'étude de la série elle-même nous permettent de conclure que, malgré cette transformation, la série étudiée possède toujours son caractère saisonnier ainsi que sa tendance. Les résultats d'un test KPSS nous confirme que la série n'est pas stationnaire (statistique = 1.0537 > 0.216, le seuil critique de 1 %).

Pour remédier à cette tendance, nous avons alors appliqué une différenciation à l'ordre 1, notre série prenant alors la forme : $Z_t = (1 - L)G_t = G_t - G_{t-1}$.

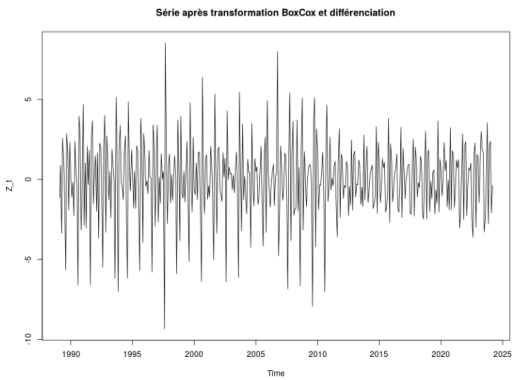

Figure 2 - Représentation de la série (Z_t)

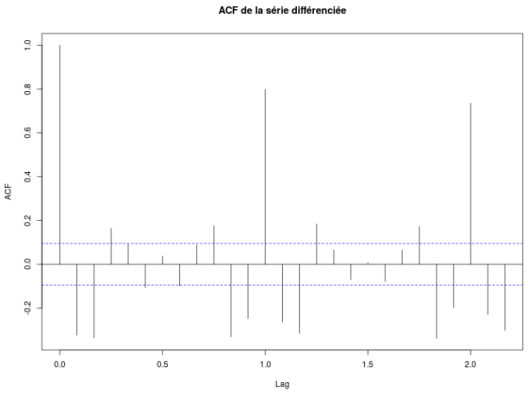

Figure 3 - ACF de la série (Z_t)

Cette transformation produit une série (Z_t) centrée et d'amplitude relativement constante. Afin de vérifier la stationnarité de manière rigoureuse, nous appliquons un test de racine unitaire (ADF) avec sélection manuelle du nombre de retards. Nous effectuons ce test pour plusieurs valeurs de k (nombre de retards autorégressifs) et, pour chaque régression, nous testons l'absence d'autocorrélation des résidus via le test de Ljung-Box. Le plus petit k pour lequel la p-value du test de Ljung-Box dépasse 5 % est retenu. Dans le cas de (Z_t), le meilleur modèle ADF est obtenu pour k=3 avec la statistique ADF = $-4.11 < -2.87$ (seuil critique à 5 %) et une p-value = 0.1088.
On en conclut que la série ainsi transformée est stationnaire et que le test est valide.

Toutefois, l'étude de son ACF (Figure 3) nous révèle qu'elle présente encore des autocorrélations notables à des lags multiples de 12, suggérant une saisonnalité résiduelle. Nous avons alors effectué une différenciation saisonnière d'ordre 12 : $Y_t = (1 - L^{12})Z_t = (1 - L^{12})(1 - L)G_t = (1 - L)(1 - L^{12})G_t$.

La série obtenue Y_t est visuellement stable autour de zéro et ne présente plus de structure cyclique marquée. Le test ADF est de nouveau appliqué selon la même méthodologie. Pour k=3, nous obtenons une statistique ADF = $-14.13 < -2.87$ et une p-value Ljung-Box = 0.0932. Les résidus du modèle sont compatibles avec un bruit blanc et l'hypothèse de racine unitaire est rejetée de manière claire.

Nous utilisons donc comme série de travail finale : $Y_t = \Delta_{12}\Delta G_t = (1 - L)(1 - L^{12})(\frac{X_t^{\lambda} - 1}{\lambda})$.

Les séries initiale et finale sont représentées ci-contre.

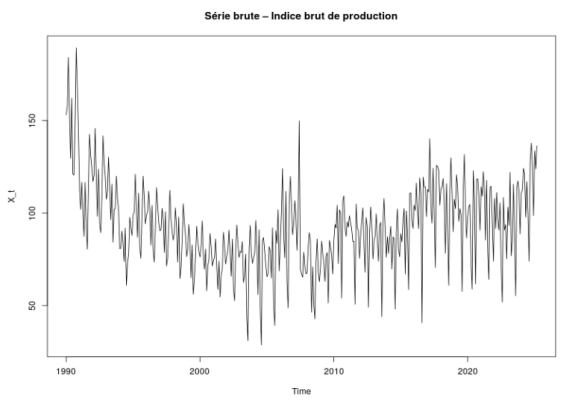

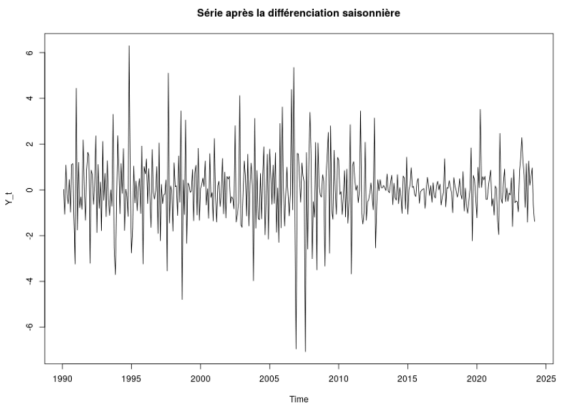

Figure 4 - Représentation de la série initiale (X_t)

Figure 5 - Représentation de la série finale (Y_t)

Partie 2: Modélisation SARIMA

Nous adoptons la démarche classique de modélisation des séries temporelles proposée par Box et Jenkins. Compte tenu de la structure saisonnière observée, il est pertinent de recourir à une modélisation SARIMA. Dans notre étude, nous nous restreindrons aux modèles sans constante.

Un processus SARIMA de forme $[(p,d,q),(P,D,Q)]_s$, avec s la période saisonnière (ici $s = 12$), est défini par l'équation suivante : $\phi(L)\Phi(L^s)(1-L)^d(1-L^s)^D X_t = \lambda(L)\Lambda(L^s)\varepsilon_t$
où $\phi, \Phi, \lambda, \Lambda$ sont des polynômes d'ordre p, P, q, Q respectivement, et ε_t est un bruit blanc. L'objectif est d'identifier les ordres (p,d,q) et (P,D,Q) qui permettent de modéliser correctement la dynamique de la série.

La démarche d'ajustement d'un modèle SARIMA suit les étapes suivantes :

1. Détermination des ordres de différenciation : La série devient stationnaire après une différenciation simple (d=1) et une différenciation saisonnière annuelle (D=1). La période est fixée à s=12. On s'intéressera donc aux modèles SARIMA de la forme $[(p,1,q),(P,1,Q)]_{12}$.
2. Identification des composantes saisonnières : Les ACF et PACF sont analysées à des retards multiples de 12 afin d'estimer les ordres P et Q.
3. Estimation des paramètres : Une fois la structure du modèle choisie, les paramètres sont estimés par moindre carrés ou maximum de vraisemblance. Le processus transformé $Y_t = (1-L)^d(1-L^s)^D X_t$ peut être interprété comme un ARMA $(p+sP, q+sQ)$.

Identification des ordres maximums pertinents

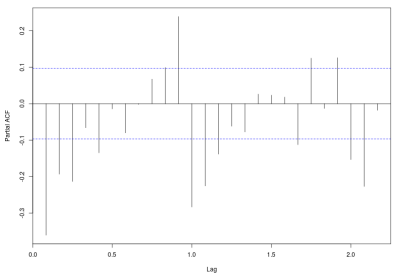

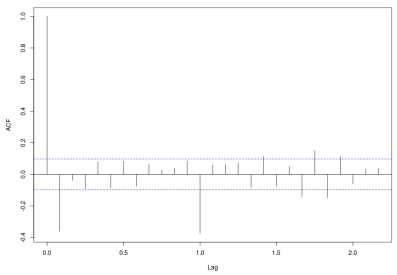

Figure 6 - PACF de la série transformée

Figure 7 - ACF de la série transformée

L'autocorrélogramme (figure 7 ci-dessus) montre des coefficients significatifs pour les premiers retards, notamment aux ordres 1 et 12, puis une décroissance rapide, indiquant une structure de type MA faible. Ce comportement suggère des ordres $q \in \{0, 1\}$ et $Q \in \{0, 1\}$. En parallèle, l'analyse de la PACF (figure PACF) révèle des retards significatifs jusqu'à des lags relativement élevés, ce qui est atypique pour un processus purement MA. Ce comportement suggère plutôt la présence d'une composante AR, orientant vers un modèle ARMA. Ainsi la PACF invite à considérer des valeurs de p supérieures à zéro, voire élevées, pour modéliser correctement la dynamique observée.

Sur la base de ces éléments, les combinaisons de paramètres candidates à tester se situent dans l'espace suivant : $q \in \{0, 1\}$, $p \in \{0, 1, 2, 3\}$, $P \in \{0, 1\}$, $Q \in \{0, 1\}$ avec $d = 1$, $D = 1$, $s = 12$.

Cette sélection restreinte permet de tester des modèles SARIMA plausibles tout en évitant une complexité inutile. La suite de l'étude portera sur l'estimation et la comparaison de ces modèles à l'aide de critères d'information (AIC, BIC) et de tests de validité.

Modèle ARIMA retenu et justification

Pour chaque modèle, nous évaluons sa validité en analysant la significativité des coefficients estimés ainsi que le comportement de ses résidus. Un modèle est considéré valide si ses résidus possèdent les caractéristiques d'un bruit blanc, à savoir une moyenne nulle, une variance constante et une absence d'autocorrélation.

Parmi les modèles testés dans l'espace restreint défini par $p, q, P, Q \in \{0, 1\}$ avec $d = 1$, $D = 1$ et saisonnalité $s = 12$, le modèle retenu est un modèle ARIMA saisonnier caractérisé par les ordres suivants :

- Partie non saisonnière : $p = 0,\ d = 0,\ q = 1$
- Partie saisonnière : $P = 0,\ D = 0,\ Q = 1$ avec une périodicité de 12.

Ce modèle inclut une composante moyenne mobile (MA) sur les parties non saisonnière et saisonnière, sans termes autorégressifs ni constante.

La sélection repose sur plusieurs critères. Tout d'abord la qualité des résidus : les résidus présentent un comportement proche de celui d'un bruit blanc, avec une moyenne statistiquement nulle et une variance stable. L'autocorrélogramme des résidus (Figure 17 Annexe 5) montre globalement peu de barres dépassant l'intervalle de confiance à 95 %, témoignant de l'absence d'autocorrélation significative, même s'il existe néanmoins quelques lags ponctuels qui dépassent cet intervalle.
Puis nous conduisons le test de Ljung-Box. La p-value associée est la meilleure parmi les modèles testés, confirmant l'absence globale d'autocorrélation significative jusqu'au lag 35.
Ensuite nous regardons la significativité des coefficients. Tous les coefficients estimés sont significativement différents de zéro à 5 %, assurant la pertinence du modèle.
Enfin nous analysons la distribution des résidus. Celle-ci est proche d'une loi normale, condition favorable pour la validité des inférences statistiques.

Enfin, ce modèle est également privilégié car il présente les valeurs les plus faibles des critères d'information AIC et BIC parmi les modèles testés.

Ainsi, le modèle ARIMA saisonnier $(0, 0, 1)(0, 0, 1)_{12}$ constitue le meilleur compromis entre robustesse, simplicité et qualité d'ajustement, offrant une base fiable pour la modélisation et la prévision, malgré la présence de quelques lags isolés légèrement au-delà des bornes de confiance.

Partie 3: Prévision

L'objectif de cette partie est de prédire les deux prochaines valeurs de la série initiale (X_t). La modélisation a été effectuée sur une série transformée, notée $Y_t = \Delta_{12}\Delta G_t$, avec (G_t) la transformation de Box-Cox de la série initiale. Nous allons donc d'abord faire les prédictions pour la série transformée (Y_t) nous remonterons à (G_t) et à (X_t) pour obtenir les prévisions des mois d'avril et mai 2025 de la production industrielle pour la fabrication d'armes et de munitions

Équation vérifiée par la région de confiance à 95 %

Le modèle retenu pour la série transformée $Y_t = \Delta_{12}\Delta G_t$, avec $G_t$la série Box-Cox transformée, est un ARIMA(0,0,1)(0,0,1)[12], ajusté après double différenciation. La dynamique de Y_t suit donc l'équation : $Y_t = \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \varepsilon_t$ où les ε_t~N(0,σ^2) sont les innovations du modèle.
La prévision conditionnelle à horizon $h \in \{1, 2\}$, notée $\widehat{Y}_{t+h}$, est obtenue par itération récursive :

- Pour h = 1 : $\widehat{Y}_{T+1} = \theta_1\varepsilon_T + \Theta_1\varepsilon_{T-11}$
- Pour h = 2 : $\widehat{Y}_{T+} = \phi_1\widehat{Y}_{T+1} + \phi_2 Y_T + \textit{composantes MA connues ou prédites}$

L'erreur de prévision à l'horizon h est notée : $Err_h = Y_{T+h} - \widehat{Y}_{T+h} = \varepsilon_{T+h}$
Sous l'hypothèse de normalité des résidus, on a: Err_1~ N(0,σ^2), $Err_2 \sim N(0, \sigma^2(1 + \theta_1^2))$

On en déduit la région de confiance à 95 % :

$$IC_{95\%}(Y_{T+1}) = [\widehat{Y}_{T+1} \pm 1.96\widehat{\sigma}] \; ; IC_{95\%}(Y_{T+2}) = [\widehat{Y}_{T+2} \pm 1.96\widehat{\sigma}.\sqrt{1 + \theta_1^2}]$$

Ces prévisions portent sur la série transformée Y_t. Afin d'obtenir les prévisions de la série initiale X_{T+1} et X_{T+2}, il est nécessaire d'inverser les transformations successives appliquées à la série.

La série transformée étant une double différenciation (saisonnière et non saisonnière) de G_t, on utilise la formule suivante pour la reconstruire: $G_t = Y_t + G_{t-1} + G_{t-12} - G_{t-13}$.

On en déduit les prévisions:

$$\widehat{G}_{T+1} = \widehat{Y}_{T+1} + G_T + G_{T-11} - G_{T-12} \text{ et } \widehat{G}_{T+2} = \widehat{Y}_{T+2} + \widehat{G}_{T+1} + G_{T-10} - G_{T-11}$$

Une fois ces prévisions obtenues, on applique la fonction inverse de Box-Cox afin de retrouver les prévisions de la série brute :

- Si λ≠0 : $\widehat{X}_{T+h} = (\lambda\widehat{G}_{T+h} + 1)^{1/\lambda}$
- Si λ=0 : $\widehat{X}_{T+h} = exp(\widehat{G}_{T+h})$

Ces prévisions $\widehat{X}_{T+1}$ et $\widehat{X}_{T+2}$ sont exprimées dans l'unité de la série brute et peuvent être directement interprétées comme un indice de production.

On ne calcule pas d'intervalle de confiance sur Y_t. Les intervalles de confiance sont directement construits sur les prévisions de G_t, puis transformés dans l'échelle de X_t.

Pour chaque horizon h, on définit : $IC_{G_{T+h}} = [\widehat{G}_{T+h} - 1{,}96.\widehat{\sigma}, \widehat{G}_{T+h} + 1{,}96.\widehat{\sigma}]$ où $\widehat{\sigma}$ est l'écart-type des résidus du modèle.

On applique ensuite la fonction inverse de Box-Cox aux bornes de ces intervalles :

- Si $\lambda \neq 0$: $IC_{X_{T+h}} = [(\lambda L + 1)^{1/\lambda}, (\lambda U + 1)^{1/\lambda}]$
- Si $\lambda = 0$: $IC_{X_{T+h}} = [exp(L), exp(U)]$

où L et U sont les bornes inférieure et supérieure de l'intervalle $IC_{G_{T+h}}$.

Ces intervalles de confiance reposent sur les hypothèses suivantes, formulées au niveau du modèle ARIMA sur Y_t:

- Les estimateurs de ϕ_i, θ_j, σ^2 ainsi que ceux des observations futures sont tous consistants.
- Les epsilons sont indépendants et suivent tous la même loi N(0, σ2).
- σ2 > 0, sinon la matrice de variance-covariance n'est pas définie positive.

Les hypothèses d'indépendance des résidus et de spécification correcte du modèle sont validées par le test de Ljung-Box et l'analyse de l'ACF des résidus. En revanche, la normalité n'a pas été formellement testée, et l'hypothèse d'homoscédasticité des résidus pourrait être remise en cause si des effets ARCH sont présents. Une analyse plus approfondie à l'aide des tests de Jarque-Bera et d'ARCH pourrait compléter cette vérification.

La figure ci-dessous présente la prévision de la série à deux pas, avec les intervalles de confiance à 95 % superposés.

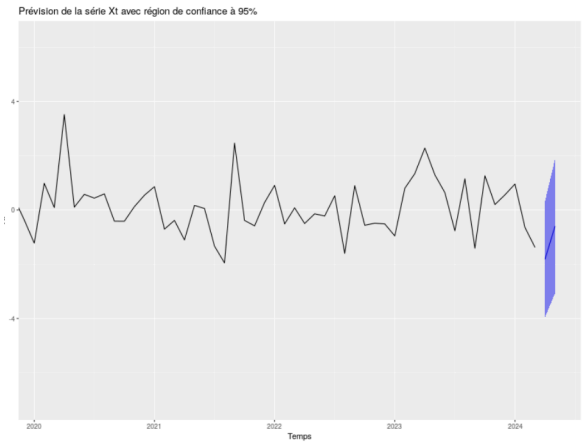

Figure 8 - Série X_t avec une prévisions à deux pas et les intervalles de confiance à 95% superposés

Question ouverte

Une variable Y_t, stationnaire et connue jusqu'à T+1, améliore la prévision de X_{T+1} si elle vérifie :
$E[X_{T+1}|X_T, Y_{T+1}] \neq E[X_{T+1}|X_T]$

Autrement dit, Y_{T+1} apporte une information utile à la conditionnelle. Cette propriété définit une causalité instantanée de Granger, testable par la comparaison des erreurs de prévision issues de deux modèles, avec et sans Y_{T+1}, ou par un test de Wald sur les coefficients associés. Ce type d'approche suppose que Y_t est observable plus rapidement que X_t.

Annexes

Annexe 1: Représentation graphique de la série (G_t) et son ACF

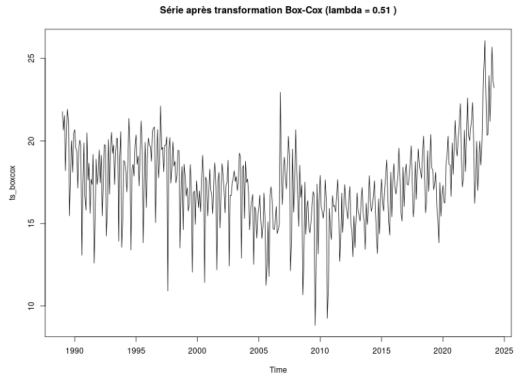

Figure 9 - Série (G_t) avec BoxCox

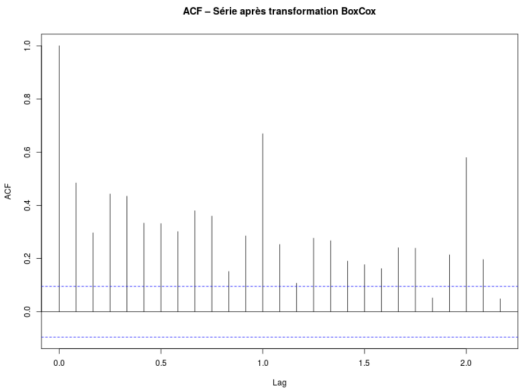

Figure 10 - ACF de la série (G_t)

Annexe 2: Représentation graphique de la série (Z_t) et son ACF

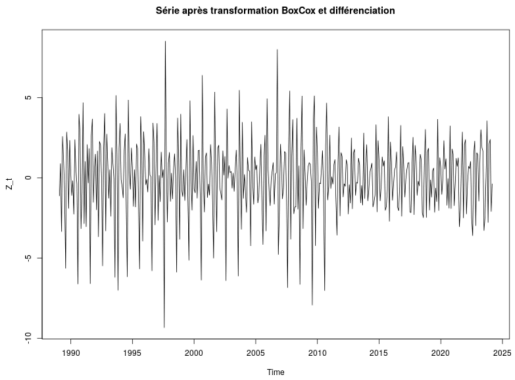

Figure 11 - Série (Z_t) avec BoxCox et différenciation

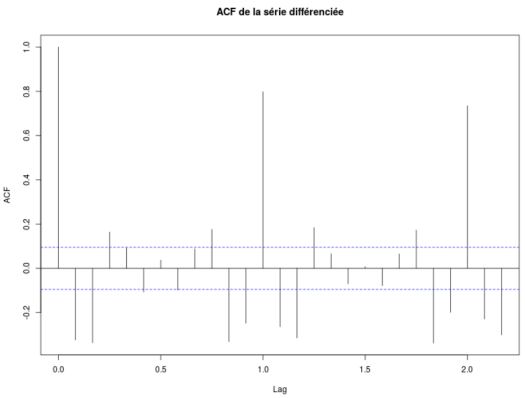

Figure 12 - ACF de la série (Z_t)

Annexe 3: Représentation graphique de la série finale (Y_t) et son ACF

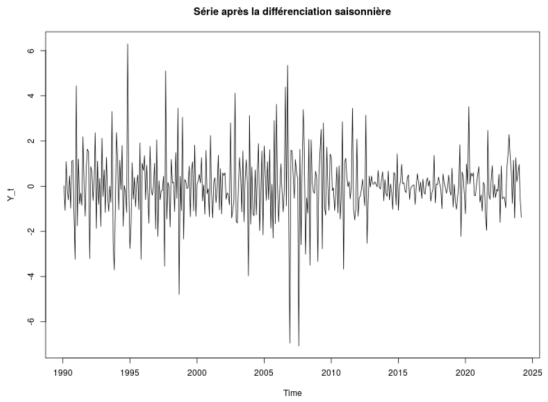

Figure 13 - Série (Y_t) avec BoxCox et différenciation et différenciation saisonnière

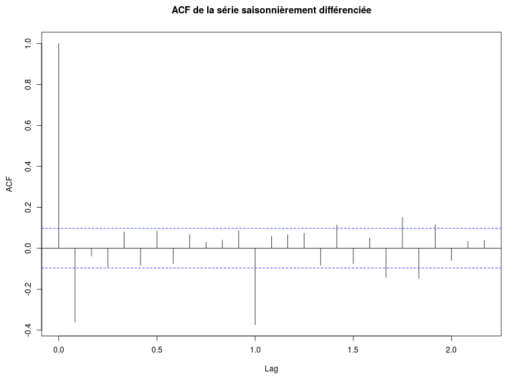

Figure 14 - ACF de la série (Y_t)

Annexe 4: Représentation graphique des PACF

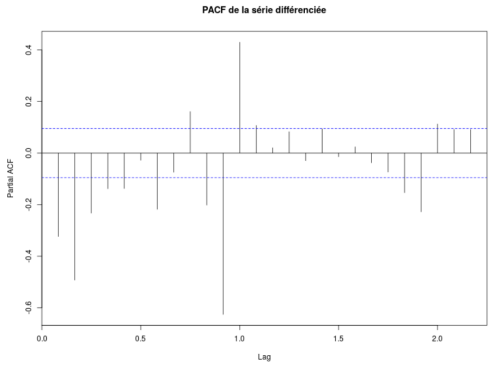

Figure 15 - PACF de la série (Z_t)

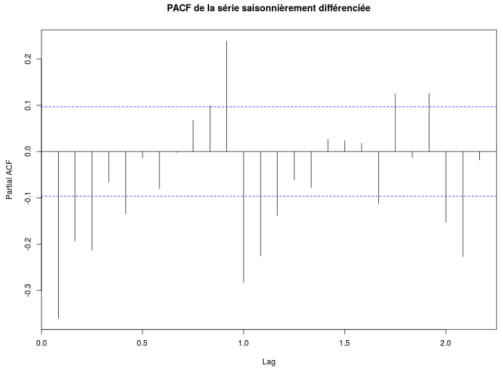

Figure 16 - PACF de la série (Y_t)

Annexe 5: Représentation graphique des caractéristiques des résidus

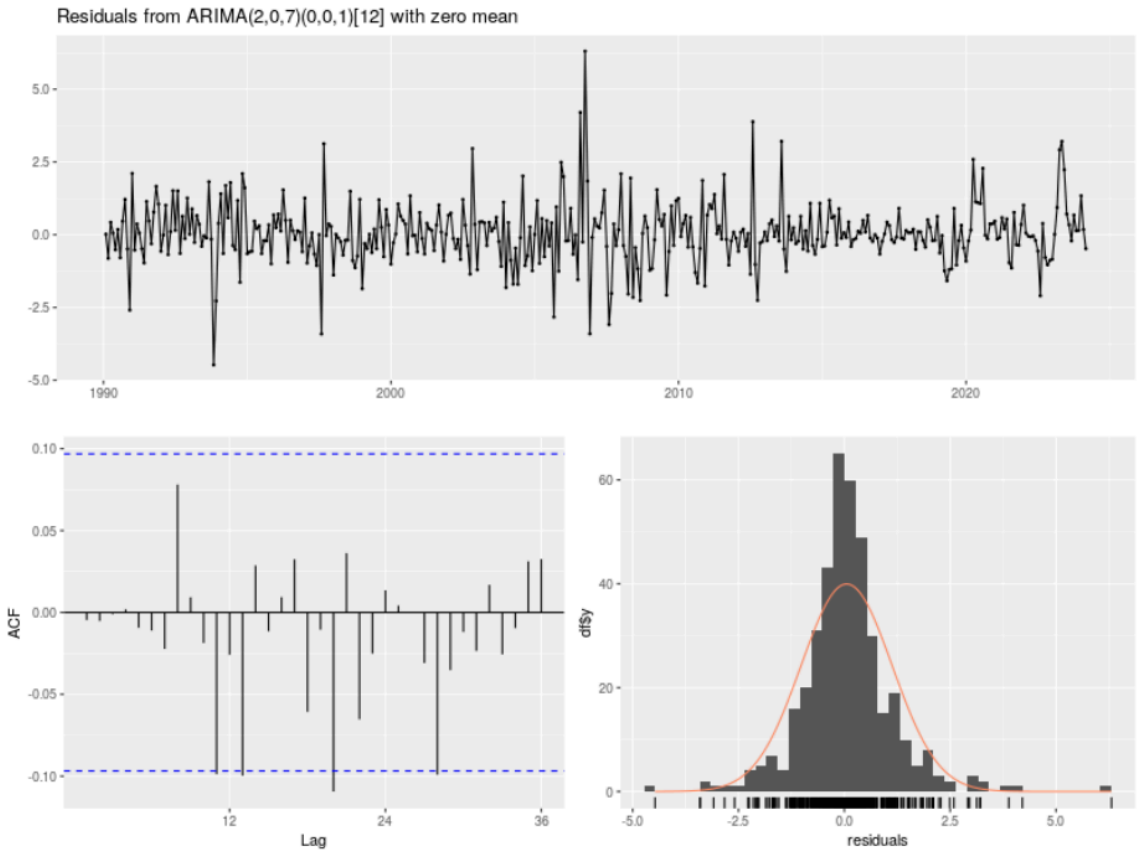

Figure 17 – Résultats de l'étude des résidus du modèle ARIMA(0,0,1)(0,0,1)[12]

Annexe 6: Tableau des différents modèles testés

Modèle	Coef.	Estimate	Std. Erreur	t-stat	p-value	Ljung-Box (lag6) Stat.	Ljung-Box (lag 6)	AIC	BIC
ARIMA(0,0,1)	ma1	-0.568013106	0.046355585	-12.25339087	0.000000e+00	10.304876	0.1123863	1409.898	1417.931
ARIMA(1,0,1)	ar1	0.198245959	0.085941715	2.30674893	2.106882e-02	5.484674	0.4833110	1406.490	1418.538
	ma1	-0.702405199	0.063614055	-11.04166676					
ARIMA(2,0,1)	ar1	0.211392720	0.110268282	1.91707638	5.522823e-02	5.257518	0.5112340	1408.451	1424.516
	ar2	0.014889130	0.110268282	0.19491418	8.454601e-01				
	ma1	-0.716804379	0.076388131	-7.32202423	2.442491e-13				
ARIMA(3,0,1)	ar1	0.062672279	0.140799526	0.44511712	6.562351e-01	3.330851	0.7663211	1408.517	1428.598
	ar2	-0.052424683	0.080861197	-0.64832931	5.167720e-01				
	ar3	-0.101089809	0.067219116	-1.50388484	1.326110e-01				
	ma1	-0.567000175	0.135942681	-4.17087679	3.034299e-05				
ARIMA(0,0,2)	ma1	-0.511817074	0.047600511	-10.75234417		6.200603	0.4010979	1407.011	1419.060
	ma2	-0.102992413	0.046441750	-2.21766863	2.657743e-02				
ARIMA(1,0,2)	ar1	0.242105550	0.337771233	0.71677374	4.735137e-01	5.370164	0.4972859	1408.470	1424.534

	ma1	-0.746852579	0.337925472	-2.21011034	2.709751e-02				
	ma2	0.026176747	0.195781105	0.13370416	8.936365e-01				
ARIMA(2,0,2)	ar1	-0.492976122	0.169655419	-2.90574933	3.663748e-03	2.669565	0.8490288	1408.264	1428.345
	ar2	0.225179069	0.086614563	2.59978301	9.328273e-03				
	ma1	-0.014115235	0.160709547	-0.08783072	9.300112e-01				
	ma2	-0.532387073	0.104275649	-5.10557430	3.297914e-07				
ARIMA(0,0,1)(0,0,1)[12]	ma1	-0.632276528	0.039907820	-15.84342431	3.021316	3.021316	0.8061668	1263.711	1275.760
	sma1	-0.721818841	0.040789090	-17.69637038					
ARIMA(1,0,1)(0,0,1)[12]	ar1	0.045527614	0.078771253	0.57797245	5.632827e-01	2.985961	0.8106068	1265.376	1281.441
	ma1	-0.659307411	0.059134312	-11.14932076	2.985961				
	sma1	-0.719073027	0.041144681	-17.47669485					
ARIMA(2,0,1)(0,0,1)[12]	ar1	0.053508131	0.101956878	0.52481139	5.997143e-01	2.926543	0.8180084	1267.362	1287.442
	ar2	0.009121394	0.074848325	0.12186504	9.030059e-01				
	ma1	-0.667464068	0.088449814	-7.54624614	4.485301e-14				
	sma1	-0.719055941	0.041166048	-17.46720839					
ARIMA(3,0,1)(0,0,1)[12]	ar1	0.009737702	0.150720826	0.06460754	9.484865e-01	2.840954	0.8318602	1268.465	1292.562
	ar2	-0.017469305	0.099836320	-0.17497945	8.610958e-01				
	ar3	-0.031327598	0.075543891	-0.41469399	6.783659e-01				
	ma1	-0.623090304	0.144218957	-4.32044662	1.557137e-05				
	sma1	-0.717172067	0.041698595	-17.19895036					
ARIMA(2,0,1)(1,0,1)[12]	ar1	0.069783201	0.103902199	0.67162391	5.018232e-01	2.813532	0.8318602	1268.465	1292.562
	ar2	0.013416879	0.075145860	0.17854449	8.582954e-01				
	ma1	-0.674917012	0.089229970	-7.56379287	3.907985e-14				
	sar1	0.069779076	0.073139448	0.95405527	3.400557e-01				
	sma1	-0.755215562	0.051088296	-14.78255542					

Annexe 7: Code R

Se conférer au script R joint au rapport.